

COMPARATIVO DE CUSTOS DE IA PARA O BOT DE SUPORTE

Valores, estimativas de consumo e recomendação para o teste em produção

Atualizado em 5 de agosto de 2026

Conclusão executiva

Para o bot atual, a opção recomendada é o Groq Developer com GPT-OSS 120B. O modelo mantém baixo custo, alta velocidade e exige pouca alteração no projeto existente.

Este documento utiliza preços públicos por token e uma simulação conservadora do fluxo atual. Os valores finais variam conforme o tamanho do histórico, número de mensagens, cache, câmbio e impostos.

Destaques

- O plano gratuito da Groq é adequado para desenvolvimento, mas os limites de tokens podem interromper atendimentos reais.
- Mil chamados completos custariam aproximadamente US\$ 5,66 no GPT-OSS 120B, segundo as premissas desta simulação.
- O ChatGPT Plus ou Business não cobre o consumo da API utilizada pelo bot.
- Para leitura de prints, recomenda-se um modelo com visão acionado somente quando houver imagem.

1. Como a cobrança funciona

As APIs cobram principalmente pelos tokens de **entrada** e de **saída**. A entrada inclui o prompt, o histórico do chamado, os POPs e as mensagens. A saída corresponde ao texto produzido pela IA.

- Os preços abaixo são informados por 1 milhão de tokens.
- Na Groq Developer não há mensalidade fixa: a cobrança ocorre conforme o uso.
- ChatGPT e API possuem cobranças separadas.

2. Valores por modelo

Modelo	Entrada / 1M	Saída / 1M	Avaliação para o bot
Groq GPT-OSS 20B	US\$ 0,075	US\$ 0,30	Muito barato, porém menos consistente
Groq GPT-OSS 120B	US\$ 0,15	US\$ 0,60	Melhor custo-benefício atual
OpenAI GPT-5.6 Luna	US\$ 0,20	US\$ 1,20	Eficiente para alto volume
Gemini 3.5 Flash-Lite	US\$ 0,30	US\$ 2,50	Multimodal, com custo maior
OpenAI GPT-5.6 Terra	US\$ 2,00	US\$ 12,00	Qualidade maior; excesso para a triagem

A OpenAI posiciona o GPT-5.6 Luna para alto volume, o Terra para equilíbrio entre capacidade e custo e o Sol para trabalhos de capacidade máxima.

3. Premissas da estimativa

A simulação considera um chamado com até 8 respostas da IA, média de 4.000 tokens de entrada e 180 tokens de saída em cada resposta. Isso representa aproximadamente 32.000 tokens de entrada e 1.440 de saída por chamado.

4. Estimativa mensal

Modelo	500 chamados	1.000 chamados	5.000 chamados
Groq GPT-OSS 20B	US\$ 1,42	US\$ 2,83	US\$ 14,16
Groq GPT-OSS 120B	US\$ 2,83	US\$ 5,66	US\$ 28,32
OpenAI GPT-5.6 Luna	US\$ 4,06	US\$ 8,13	US\$ 40,64
Gemini 3.5 Flash-Lite	US\$ 6,60	US\$ 13,20	US\$ 66,00
OpenAI GPT-5.6 Terra	US\$ 40,64	US\$ 81,28	US\$ 406,40

Usando apenas como exemplo um câmbio de R\$ 5,50 por dólar, 1.000 chamados no GPT-OSS 120B custariam aproximadamente R\$ 31,15, antes de impostos e variação cambial.

O custo pode ser menor quando o cache reaproveita partes repetidas do prompt. Na Groq, a entrada em cache do GPT-OSS custa 50% menos.

5. Por que o plano gratuito acaba rápido

Os limites gratuitos publicados para o GPT-OSS 120B incluem 30 requisições por minuto, 1.000 por dia, 8.000 tokens por minuto e 200.000 tokens por dia. Como o bot envia histórico, regras e POPs, o limite de tokens tende a ser atingido antes do limite de requisições.

Na simulação deste relatório, o teto diário de 200 mil tokens comportaria aproximadamente seis atendimentos completos. Os limites exatos devem ser confirmados no painel da organização.

6. Recomendação

**Adotar Groq Developer com GPT-OSS 120B para o teste real.
A diferença de preço em relação ao 20B é pequena, enquanto o ganho esperado de consistência no acompanhamento dos POPs e da conversa é mais relevante.**

- Definir limite inicial de US\$ 20 por mês.
- Criar alertas de consumo em 50%, 75% e 90%.
- Acompanhar volume e qualidade durante duas a quatro semanas.
- Usar um modelo com visão apenas quando houver print ou anexo.

O GPT-OSS 120B servido pela Groq é textual. A futura leitura de imagens deve ser implementada como uma rota separada, mantendo o custo principal da conversa baixo.

Fontes oficiais

- Groq - preços
<https://groq.com/pricing>
- Groq - cobrança e plano Developer
<https://console.groq.com/docs/billing-faqs>
- Groq - limites gratuitos
<https://console.groq.com/docs/rate-limits>
- Groq - cache de prompt
<https://console.groq.com/docs/prompt-caching>
- Groq - GPT-OSS 120B
<https://console.groq.com/docs/model/openai/gpt-oss-120b>
- Groq - limites de gastos
<https://console.groq.com/docs/spend-limits>
- OpenAI - preços da API
<https://developers.openai.com/api/docs/pricing>
- OpenAI - guia da família GPT-5.6
<https://developers.openai.com/api/docs/guides/latest-model.md>
- OpenAI - ChatGPT Business e API
<https://help.openai.com/en/articles/8792828-what-is-chatgpt-team>
- Google - preços da API Gemini
<https://ai.google.dev/gemini-api/docs/pricing>

Nota: preços, modelos, limites e condições podem mudar. Antes da contratação, confirme os valores nas páginas oficiais e no painel da conta.